

CLASE 8

Microestructura y Alta Frecuencia

Clase 8: Del libro de órdenes al HFT

Guido Schifani

FCEN · UBA



§1

El libro de órdenes: la máquina que hace los precios

Órdenes límite y de mercado · Matching · Fragmentación · NBBO

▶ Hoy bajamos al microsegundo

- El 'precio' que usamos hasta ahora es un RESUMEN

▶ Lo que cambia al hacer zoom

- No hay UN precio: hay un bid, un ask, y un libro entero de intenciones a cada lado
- El precio no 'se mueve': alguien CRUZA el spread y consume órdenes de otros
- El tiempo es discreto y por eventos: órdenes que llegan, se cancelan, se ejecutan
(las dollar bars de la clase 6 eran esto: muestrear por eventos)




▶ Por qué le importa a cada quant (aunque no haga HFT)

- Los costos por pata de ejecutar salen de ACÁ, los costos de ejecución son microestructura
- El ruido que contaminaba la vol realizada (dollar bars, clase 6): microestructura

- ▶ **Orden LÍMITE: 'compro hasta 100.00, ni un centavo más', precio garantizado, ejecución NO**
 - Se sienta en el libro a esperar; provee liquidez; puede no ejecutarse nunca
- ▶ **Orden de MERCADO: 'compro YA, al precio que haya', ejecución garantizada, precio NO**
 - Cruza el spread y consume el libro; demanda liquidez; paga el costo de la urgencia
- ▶ **Las cuatro variables fundamentales**
 - BID: el mejor precio de compra esperando. ASK: el mejor de venta.
 - SPREAD = ask – bid: el precio de la inmediatez
 - MID = (bid+ask)/2: el 'precio' que reportan los gráficos, una ficción útil
- ▶ **El zoológico de variantes: qué agregan sobre las dos primitivas**
 - STOP: se activa como orden de mercado recién si el precio toca un nivel (protección/breakout)
 - ICEBERG: solo muestra una fracción del tamaño real, el resto se revela de a poco al ejecutarse
 - IOC/FOK: ejecutar lo que se pueda YA (o todo o nada), y cancelar el resto — para no dejar huella

- ▶ **Bid a \$99.98 con tres órdenes en cola, en orden de llegada: A(200 acc.), B(150), C(400)**
 - Llega una orden de mercado de venta por 300 acciones
- ▶ **Con FIFO (First In, First Out: el primero en llegar, el primero en cobrar — la regla dominante)**
 - A se llena completo (200), B se llena parcial (100 de 150), C no recibe nada — llegar primero paga
- ▶ **Si en cambio A hubiera llegado 1 milisegundo después que B**
 - El orden cambia completo: B se llena primero — ese milisegundo vale la diferencia entre cobrar y no cobrar
- ▶ Esta es la motivación económica exacta detrás de toda la carrera de latencia

El libro de órdenes real — AAPL, apertura 2026-08-06



AAPL, libro real de 10 niveles, apertura del 2026-08-06. Izquierda: escalera de bids y asks con su profundidad en cada nivel. Centro: la profundidad acumulada, cuánto hay que 'comerse' del libro para mover el precio. Derecha: 60 segundos reales de midprice, mejor bid/ask y trades ejecutados.

- ▶ **La regla de casi todos los mercados: prioridad PRECIO-TIEMPO (FIFO)**
 - Mejor precio ejecuta primero; a igual precio, el que llegó antes
 - Consecuencia enorme: la POSICIÓN EN LA COLA es un activo, llegar antes vale plata


- ▶ **La alternativa: pro-rata (algunos futuros y opciones)**
 - A igual precio, el fill se reparte proporcional al tamaño, premia órdenes grandes, no velocidad
 - Ejemplo: bid con 3 órdenes de 100/300/600 acc. FIFO da todo a la primera; pro-rata reparte 10/30/60% de cada fill

 - La regla del matching CAMBIA las estrategias óptimas, el diseño de mercado importa


- ▶ **Fragmentación: no hay UN libro, hay dieciséis**
 - En USA: 16 exchanges + ~30 dark pools operan LA MISMA acción simultáneamente
 - Dark pools: sin libro visible, matchean al mid del mercado lit, ~15% del volumen US

El matching engine: FIFO vs pro-rata

Matching Engine — flujo de órdenes y arquitectura del mercado electrónico



FIFO vs Pro-rata — asignación de trades (orden agresiva de 200 acciones contra el LOB)



La mecánica del matching: con FIFO la cola premia la velocidad de llegada; con pro-rata, el tamaño. La misma orden de mercado produce fills distintos según la regla, el diseño del mercado moldea el comportamiento de todos sus participantes.

- ▶ **No hay 'el' bid ni 'el' ask: la misma acción cotiza en ~16 venues a la vez**

- Hay un vector de bids y asks, uno por venue, hace falta agregarlos en un solo número

- ▶ **El NBBO (National Best Bid and Offer): el mejor precio de TODO el mercado**


$$\text{NBBO}_t = \left(\max_i \text{bid}_{i,t}, \min_i \text{ask}_{i,t} \right)$$

- El SIP consolida los 16 feeds y lo publica — con demora, no instantáneo
- Los feeds DIRECTOS de cada exchange llegan antes: esa brecha de microsegundos es el negocio del arbitraje de latencia (§5)

- ▶ La fragmentación es deliberada: varios venues compitiendo le quita poder de mercado a cualquiera de ellos — el costo es la complejidad de hoy

El NBBO en acción: el mejor precio, agregado entre venues

NBBO: el mejor precio, agregado entre venues fragmentados



Cinco venues, cada uno con su propio bid y ask (simulado). El NBBO toma el mejor bid de TODOS (BATS acá) y el mejor ask de TODOS (IEX acá), sin importar que ningún venue individual ofrezca ese spread completo.

Dark pools, internalización y feeds directos: lo que no ves, y lo que cuesta ver antes

▶ No todo el flujo llega al libro público

- Internalización: tu bróker (o un wholesaler como Citadel Securities) ejecuta tu orden SIN mandarla a un exchange, a un precio $\geq$ NBBO
- Dark pools: libros SIN cotizaciones visibles, matchean al mid — ocultan intención, pero restan volumen a la formación de precio

▶ Ver el NBBO antes que otros también cuesta plata

- El SIP consolida y retransmite: no es instantáneo. Los feeds directos (sin pasar por el SIP) llegan antes, por microsegundos
- El bróker retail promedio usa el SIP; los HFT pagan por los directos — esa brecha es lo que compra el arbitraje de latencia (§5)

§2

¿De dónde sale el spread?: tres teorías

Inventario (Stoll) · Selección adversa (Glosten-Milgrom) · Información (Kyle)

▶ El elenco del mercado (el juego de información asimétrica)

- INFORMED: sabe algo del valor V que el mercado no, fracciona sus órdenes para no delatarse
- NOISE: opera por razones ajenas al precio (rebalanceos, liquidez), la lubricación del mercado
- MARKET MAKER: cotiza ambos lados sin saber quién le habla, infiere del flujo

▶ Sin noise traders no hay mercado

- Si TODA orden fuera informada, el MM sabría que pierde sistemáticamente y dejaría de cotizar — el mismo colapso

▶ La liquidez no es un número, es un EQUILIBRIO frágil entre tipos de traders

▶ **Teoría 1, Inventario (Stoll 1978): el spread paga el riesgo de cargar posición**

- Cada fill deja al MM con inventario que no eligió, expuesto a σ — el spread compensa ese riesgo
- Es EXACTAMENTE el problema que Avellaneda-Stoikov resuelve en forma óptima (§4)

▶ **Teoría 2, Glosten-Milgrom (1985): el spread como seguro contra el que sabe**

- Mezcla de informados (μ) y ruido; que te compren ES información $\rightarrow \text{Ask} > E[V] > \text{Bid}$, el spread nace de Bayes
- El precio converge trade a trade — el Kalman de la clase 7, hecho mercado

▶ **Teoría 3, Kyle (1985): λ , el precio de mover el mercado**

$$p = \mu_0 + \lambda y \quad \lambda = \frac{\sigma_V}{2\sigma_u}$$

- El informado dosifica cuánto opera (revela exactamente LA MITAD de su información); λ es la versión micro del impacto de §3
- ▶ Las tres NO compiten, SUMAN: ~50% selección adversa + ~35% inventario + ~15% procesamiento (Madhavan et al. 1997)

De dónde sale λ : el equilibrio de Kyle (1985), paso a paso

▶ **1) El informado elige cuánto operar (x) para maximizar su ganancia esperada π**

$$\pi = \mathbb{E}[(V - p)x] = (V - \mu_0)x - \lambda x^2 \quad \Rightarrow \quad x^* = \frac{V - \mu_0}{2\lambda}$$

- π es su ganancia esperada: compra barato ($V - p$) por x , pero cuanto más grande x , más mueve el precio en su contra (el término λx^2)

▶ **2) El market maker ve solo el flujo TOTAL $y = x + u$ (no distingue informado de ruido) y fija p**

$$p = \mathbb{E}[V | y] = \mu_0 + \frac{\beta \sigma_V^2}{\beta^2 \sigma_V^2 + \sigma_u^2} y$$

- 'Fijar el precio bayesiano' es esto: actualizar el prior μ_0 con la evidencia y , la misma fórmula de proyección normal que Kalman/Black-Litterman — β acá es la CONJETURA del MM sobre cuánto opera el informado por unidad de $(V - \mu_0)$

▶ **3) Consistencia: la conjetura del MM (β) y lo que el informado REALMENTE elige ($\beta = 1/(2\lambda)$, del paso 1) tienen que coincidir — es un punto fijo**

- Resolver ese punto fijo da $\lambda = \sigma_V / (2\sigma_u)$ — exactamente la fórmula de la slide anterior

▶ Cada jugador optimiza dado lo que espera del otro, y el equilibrio es donde esa expectativa se confirma sola

Comparando las tres teorías: qué predice cada una, y cómo se distingue

- ▶ **Las tres explican el MISMO spread desde ángulos distintos, y hacen predicciones DIFERENTES**
 - Stoll (inventario): el spread crece con σ , y se ANGOSTA después de que el MM descarga posición
 - Glosten-Milgrom (selección adversa): el spread se ENSANCHA antes de anuncios (earnings, Fed) — más μ efectivo
 - Kyle (información/ λ): el spread/impacto es proporcional al FLUJO, no solo al tiempo transcurrido
- ▶ **Cómo se distinguen empíricamente (Madhavan-Richardson-Roomans 1997, la referencia de la descomposición)**
 - Miran la autocovarianza de trades y quotes en secuencia: cada componente deja una firma temporal distinta
- ▶ El resultado ya visto: ~50/35/15% selección adversa/inventario/procesamiento en una acción líquida típica

§3

Market impact y ejecución óptima

La square-root law · Almgren-Chriss (5ª vida del resorte) · VWAP/TWAP/POV

▶ **La pregunta del fondo grande: ¿cuánto me cuesta comprar el 5% del volumen diario?**

$$\Delta p \approx Y\sigma \sqrt{\frac{Q}{V}} \quad (Q \text{ tu orden, } V \text{ volumen diario, } Y \sim 0.5-1)$$

- ¿De dónde sale esta fórmula? De NINGÚN modelo — es un ajuste EMPÍRICO a datos de ejecuciones reales, no una derivación (por eso Y varía según mercado/época, nadie tiene una fórmula que lo fije)
- El impacto crece con la RAÍZ del tamaño, no lineal: la 4ª orden igual mueve menos que la 1ª

▶ **Por qué es notable, pese a no venir de un modelo**

- Se cumple en acciones, futuros, FX, crypto, opciones, épocas y países distintos
- Con el MISMO exponente ~ 0.5 , el tipo de universalidad que un físico respeta
- Y NO es obvia: Kyle (§2) predice impacto lineal — la raíz sigue siendo un puzzle teórico abierto




▶ **Las consecuencias de negocio**

- La capacidad de toda estrategia es finita

- ▶ **Cuando ejecutás, el precio se mueve, pero no todo ese movimiento es igual de duradero**
 - Impacto TEMPORARIO: el precio vuelve (parcialmente) apenas dejás de operar — consumiste liquidez que se repone
 - Impacto PERMANENTE: una fracción del movimiento queda, porque tu orden reveló información (Kyle, §2)
- ▶ **Por qué separar los dos importa para el negocio**
 - El temporario es un COSTO puro de tu ejecución (lo pagás vos, evitable con velocidad óptima)
 - El permanente refleja el verdadero cambio de valoración del mercado (no es 'culpa' de tu ejecución)

Market impact con datos reales: dos fracasos instructivos, y la ley que SÍ aparece

Market impact con datos reales — libro, trades y la ley de raíz cuadrada (2026-08-06)



Izquierda: caminar el libro VISIBLE real (6 tickers) da $b \approx 0.85$, no 0.5 — consumir el libro de una sola vez es mecánicamente distinto de una metaorden ejecutada en el tiempo. Centro: trades grandes reales de AAPL (p99, aislados) NO revierten en 40s — el impacto es casi todo permanente (información, §2), no ruido de liquidez. Derecha, la ley SÍ aparece con la metodología correcta: trades consecutivos del mismo lado (proxy de una metaorden real, no un trade suelto) y la normalización estándar de la literatura (Tóth et al. 2011) — tamaño como participación $Q/V_{\text{día}}$, impacto sobre la volatilidad propia de cada activo. Con eso, los 6 tickers COLAPSAN sobre una sola curva: $b \approx 0.53$, robusto en un rango de parámetros razonable. La lección completa: la ley es real, pero hace falta el proxy correcto de metaorden y la normalización correcta entre activos — ningún atajo (libro estático, un trade suelto, volumen total del día) la reproduce solo.

- ▶ **El problema: vender X acciones en T horas, ¿a qué ritmo?**
- ▶ **Los dos costos en tensión (no se pueden minimizar juntos)**
 - RÁPIDO: pagás mucho IMPACTO (consumís el libro, la square-root law te factura)...
 - ...pero poco RIESGO (terminás antes de que el precio se mueva en contra)
 - LENTO: impacto mínimo... pero quedás expuesto a σ durante horas, el riesgo de mercado
- ▶ **La formalización (Almgren & Chriss, 2001)**
$$\min_{x(t)} \mathbb{E}[\text{costo}] + \gamma \text{Var}[\text{costo}]$$
 - Impacto temporario $\propto$ velocidad de ejecución; riesgo $\propto$ lo que queda por ejecutar
 - ¿Les suena la estructura? Es MARKOWITZ EN EL TIEMPO, media-varianza sobre trayectorias
 - y es la aversión del cliente: el pension fund paciente y el hedge fund urgente ejecutan DISTINTO

▶ La trayectoria óptima (con impacto lineal: forma cerrada)

$$x(t) = X \frac{\sinh(\kappa(T-t))}{\sinh(\kappa T)} \quad \kappa \propto \sqrt{\frac{\gamma \sigma^2}{\eta}} \quad \text{coeficiente de impacto temporal}$$

- $\gamma \rightarrow 0$ (indiferente al riesgo): ejecución LINEAL (el TWAP), puro ahorro de impacto
- γ grande: ejecución FRONT-LOADED, sacarse el riesgo de encima rápido, pagando impacto
- κ : el 'urgency parameter'

▶ La frontera de ejecución, el gemelo de Markowitz


- Cada γ da un punto (riesgo, costo esperado): la curva de trade-offs eficientes
- Ningún cronograma la mejora en ambas dimensiones, se ELIGE un punto, no 'el óptimo'

El menú de algoritmos de ejecución: TWAP, VWAP, POV y Almgren-Chriss


- ▶ **Los tres 'ingenuos': reglas fijas, no resuelven ningún trade-off explícito**
 - TWAP (Time-Weighted): ritmo CONSTANTE en el tiempo, sin mirar el mercado — es el $\gamma \rightarrow 0$ de Almgren-Chriss
 - VWAP (Volume-Weighted): sigue la FORMA del volumen intradiario — rápido cuando el mercado ya está activo
 - POV (Percentage of Volume): ejecuta una fracción FIJA del volumen que va pasando EN VIVO (ej. 20%) — se adapta solo, pero puede tardar si el mercado está tranquilo
- ▶ **El único que resuelve un trade-off explícito: Almgren-Chriss**
 - La trayectoria que acabamos de derivar — el único que balancea impacto vs riesgo con un γ elegido

Optimal Execution Algorithms — TWAP, VWAP, POV, Almgren-Chriss


Optimal Execution — comparación de algoritmos
TWAP · VWAP · POV · Almgren-Chriss y AC con drift



Perfil de volumen intradía típico
(U-shape: alto al open y close)



Trade-off: impact vs timing risk
(AC minimiza el total; AC+ α prioriza speed)



Las trayectorias de Almgren-Chriss para distintas aversiones: del TWAP lineal ($\gamma \approx 0$) al front-loading agresivo. Cada trayectoria es un punto en la frontera costo-riesgo, Markowitz en el tiempo. El VWAP con su perfil en U es el pariente práctico que corre en todos los brokers.

- ▶ **Vender 1M de acciones en 1 día (σ diaria 2%, participación objetivo 10% del volumen)**
 - y chico (fondo paciente): $\kappa \approx 0.5/\text{día}$ → trayectoria casi lineal, costo esperado bajo, riesgo alto
 - y grande (urgente): $\kappa \approx 4/\text{día}$ → el 60% se ejecuta en el primer cuarto del día, costo alto, riesgo bajo

- ▶ **Los nombres de las pantallas, y dónde caen en el mapa de Almgren-Chriss**
 - TWAP: ritmo constante, el caso $\gamma \rightarrow 0$ exacto
 - VWAP: sigue el perfil de volumen en U del día (no está EN la frontera, pero es un benchmark defendible)
 - POV: % constante del volumen, se adapta si el mercado acelera o frena
 - Implementation Shortfall (= A-C aplicado): el estándar institucional, medir TODO contra el precio de decisión

- ▶ **La forma del volumen intradiario: NO es plano, tiene forma de 'U' (sonrisa)**
 - Mucho volumen a la apertura (descubrimiento de precio tras la noche) y al cierre (rebalanceos, índices)
 - Poco volumen al mediodía, el 'valle' de la sonrisa
- ▶ **El algoritmo VWAP: replicar esa forma con tu propia ejecución**
 - Si el mercado históricamente hace 8% del volumen en la primera hora, vos ejecutás ~8% de tu orden ahí
 - No optimiza costo-riesgo explícitamente (por eso no está en la frontera de Almgren-Chriss)
- ▶ Pero es robusto: funciona razonablemente en casi cualquier día, sin necesitar estimar σ , γ , ni κ

\$4

Avellaneda-Stoikov: el market making óptimo

Precio de reserva · Spread óptimo · El inventario manda · Extensiones

El problema del market maker: ganar el spread sin morir de inventario

- ▶ **El negocio (§1): cotizar bid y ask, cobrar el spread en cada ida y vuelta**
 - El riesgo (§2, Stoll): cada fill te deja inventario que NO elegiste, expuesto a σ
 - Cotizás pasivamente... y el mercado decide CUÁNDO te pega, y te pega cuando le conviene a él
- ▶ **El setup del modelo (Avellaneda & Stoikov, 2008)**
 - El mid se mueve como browniano (sin drift, el MM no predice, administra)
 $dS_t = \sigma dW_t$
 - El MM elige sus distancias al mid: δ_{bid} y δ_{ask} , sus dos variables de control
 $\lambda(\delta) = A e^{-k\delta}$ (cuanto más lejos cotizo, menos me ejecutan)
 - A: cuánto flujo hay; k: cuán sensible es el flujo al precio
 - Objetivo: maximizar utilidad de la riqueza final (γ = aversión al riesgo)
- ▶ **Es un problema de CONTROL ESTOCÁSTICO, se resuelve con la ecuación HJB (Hamilton-Jacobi-Bellman)**

► El problema planteado como HJB

$$u(s, x, q, t) = \max_{\delta^b, \delta^a} \mathbb{E}[-e^{-\gamma(X_T + q_T S_T)}]$$

s : precio medio

x : capital cash

q : inventario acumulado

t : tiempo al cierre

- Maximizar la utilidad esperada del P&L final, eligiendo δ_{bid} y δ_{ask} en cada instante

► El truco que lo hace resoluble: la utilidad no ve la riqueza YA acumulada

- Con utilidad exponencial, el problema es invariante a la riqueza ganada hasta ahora — solo importan las decisiones futuras
- Eso habilita el ansatz $u = -e^{-\gamma x} \cdot (\text{algo que depende solo de } s, q, t)$: la EDP en 4 variables se reduce a 3

► **La ecuación HJB completa (con los saltos de bid y ask, explícitos)**

$$0 = u_t + \frac{1}{2}\sigma^2 u_{ss} + \max_{\delta^b} \lambda^b(\delta^b) \Delta^b u + \max_{\delta^a} \lambda^a(\delta^a) \Delta^a u$$

- $\Delta^b u = u(s, x - (s - \delta^b), q+1, t) - u(s, x, q, t)$: el salto si se llena el bid (cobro $s - \delta^b$, sumo inventario)
- $\Delta^a u$ definido simétrico para el ask — bid y ask se maximizan POR SEPARADO, cada uno en su propio término

► **El ansatz $u = -e^{\{-\gamma x\}} \cdot w(s, q, t)$, reemplazado, y dividido por $e^{\{-\gamma x\}}$**

$$w_t + \frac{1}{2}\sigma^2 w_{ss} = \max_{\delta^b} \lambda^b(\delta^b) \left[w(s, q, t) - e^{\gamma(s - \delta^b)} w(s, q+1, t) \right] + (\dots)_{\delta^a}$$

- El término $(\dots)_{\delta^a}$ es EL MISMO con $\delta^b \rightarrow \delta^a$, $q+1 \rightarrow q-1$ (la ask es el espejo del bid — por eso se maximizan aparte)

La solución: dos fórmulas que se leen como consejos

▶ Resultado 1, el PRECIO DE RESERVA: tu centro no es el mid

$$r = S - q \gamma \sigma^2 (T - t)$$

- q = tu inventario. Si estás comprado ($q > 0$), tu centro baja: cotizás para ATRAER VENTAS
- El MM 'inclina la cancha' para que el flujo lo devuelva a inventario cero
- El castigo crece con γ , σ^2 y el tiempo restante, cada término tiene sentido de negocio

▶ Resultado 2, el SPREAD ÓPTIMO alrededor de ese centro





$$\delta_a + \delta_b = \gamma \sigma^2 (T - t) + \frac{2}{\gamma} \ln\left(1 + \frac{\gamma}{k}\right)$$

- Término 1: prima por riesgo de inventario (sube con γ y σ^2 , Stoll formalizado)
- Término 2: cuánto podés cobrar dado cuán sensible es el flujo (k), el poder de mercado

▶ Las quotes finales: SIMÉTRICAS alrededor de r , ASIMÉTRICAS alrededor del mid

- Esa asimetría ES la gestión de inventario, la firma visual del MM óptimo (la figura)

Modelo de Avellaneda-Stoikov — Market Making óptimo bajo riesgo de inventario



Simulación Monte Carlo (500 paths, no datos de mercado): el precio de reserva desviándose del mid según el inventario; el inventario oscilando alrededor de cero (las quotes lo empujan, el resorte); el spread creciendo con γ ; y el veredicto: sobre cientos de simulaciones, A-S le gana al market maker ingenuo, no por cobrar más, sino por explotar menos.

- ▶ **γ (aversión al riesgo del MM): sube $\rightarrow$ spread MÁS ancho, inventario objetivo MÁS cerca de cero**
 - σ (volatilidad del mid): sube $\rightarrow$ ambas fórmulas responden con más fuerza, el riesgo de cargar posición se encarece
 - k (sensibilidad del flujo al precio): sube $\rightarrow$ el mercado 'castiga' cotizar lejos, el spread óptimo se angosta
 - $T-t$ (tiempo restante): baja $\rightarrow$ el término de riesgo de inventario se apaga, solo queda el poder de mercado
- ▶ **La intuición de conjunto que hay que llevarse**
- ▶ Cada parámetro tiene un rol económico legible, nada es una caja negra ajustada por prueba y error

Cómo se calibra (cada pocos segundos)

- ▶ σ : rolling sobre los últimos 5-15 minutos del mid
- ▶ A y k : del fit de la intensidad de fills vs distancia (regresión log-lineal, slide anterior)
- ▶ γ : el dial de la casa, cuánto inventario se tolera $[0.01, 1]$
- ▶ T : fin del día, o un horizonte rodante que nunca llega
- ▶ Todo se re-estima en vivo: el modelo es un esqueleto, la calibración es el músculo

Lo que le falta al esqueleto original

- ▶ σ constante $\rightarrow$ en la práctica se usa vol estocástica (Heston, clase 3) para σ_t
- ▶ Fills Poisson $\rightarrow$ en realidad hay clustering: procesos de Hawkes (§5)
- ▶ Sin señal de flujo $\rightarrow$ falta anticipar hacia dónde va el mercado, no solo administrar inventario
- ▶ Un solo activo $\rightarrow$ falta coordinar quotes en varios activos correlacionados a la vez

- ▶ **El modelo básico deja que q crezca sin límite si el flujo lo empuja para ese lado**
 - En producción esto es inaceptable: un desk tiene un límite DURO de riesgo, no solo una preferencia (γ) por evitarlo
- ▶ **La solución práctica más simple: γ que crece con $|q|$**
 - Cerca del límite $Q_{\max}$, la aversión efectiva se dispara, las quotes se inclinan agresivamente para descargar
 - Es una aproximación barata al problema con restricciones duras que resuelven Guéant-Lehalle-Tapia (próxima slide)

▶ **Cartea & Jaimungal (2015): agregan una señal de order flow al precio de reserva**

$$r = S - q\gamma\sigma^2(T-t) + \psi \cdot \widehat{\text{OFI}}_t$$

- ψ pondera una predicción de hacia dónde va el precio (el OFI de §5): el MM deja de ser ciego al flujo
- También incorporan selección adversa explícita: quotes que se retiran cuando el flujo se vuelve tóxico

▶ **Guéant, Lehalle & Fernandez-Tapia (2013): multi-activo con límites duros de inventario**

- En vez de un solo q , un vector de inventarios correlacionados, con un límite Q_{max} que no se puede cruzar
- Resuelven con un sistema de ecuaciones (no una fórmula cerrada única), pero el esqueleto sobrevive

▶ El punto que conecta todo: reserva + spread es el diseño correcto, las extensiones lo enriquecen, no lo reemplazan

Avellaneda-Stoikov vs Almgren-Chriss: dos caras del mismo control óptimo

- ▶ **Ambos son control estocástico (HJB) sobre inventario/posición bajo un browniano — la misma familia matemática**
 - Almgren-Chriss (§3): el objetivo es DESHACERSE de una posición conocida, en un horizonte fijo, sin fills inciertos
 - Avellaneda-Stoikov (§4): el objetivo es GANAR el spread, con fills inciertos (Poisson) que generan la posición

- ▶ **Por qué comparten la misma forma matemática (κ , resorte)**
 - En ambos, alejarse del objetivo (posición cero, o inventario cero) cuesta más cuanto más lejos se está —

\$5

Un vistazo a HFT y a los sistemas que lo ejecutan

La escala más rápida del curso, el cierre

El mapa de esta última parte, en una frase por tema

- ▶ **Física (latencia): cuánto cuesta la distancia, en microsegundos**
 - Economía (opción gratis): cuánto VALE ganar la carrera de velocidad, en dólares
 - Señal (OFI): qué se puede leer del desbalance del libro a muy corto plazo
 - Dinámica (Hawkes): por qué el flujo de órdenes llega en ráfagas, no parejo
 - Sistemas (C++): por qué todo esto necesita código que no pague peajes de intérprete
 - Patologías (Flash Crash, Knight): qué pasa cuando todo lo anterior interactúa mal

▶ **Todo esto nace de dos hechos de \$1, llevados a su consecuencia extrema**

- La COLA (FIFO): Llegar antes = mejor posición. La FRAGMENTACIÓN: el precio cambia en un venue,
- hay una ventana de microsegundos para operar el precio viejo en los demás

▶ **La física, resumida**

$$t = \frac{d \cdot n}{c} \quad n_{\text{fibra}} \approx 1,47, \quad n_{\text{microondas}} \approx 1,0003$$

- Colocation (servidor en el datacenter del exchange), kernel bypass, FPGA: cada escalón, una industria
- ▶ Spread Networks gastó USD 300M en fibra Chicago-NY para ahorrar 3ms... y las microondas la superaron en 2 años

- ▶ **Una vez en el datacenter del exchange, la carrera sigue en metros, no kilómetros**
 - Colocation: alquilás un rack DENTRO del mismo edificio que el matching engine
 - El cross-connect (el cable de tu rack al switch del exchange) se cobra por metro
 - Muchos exchanges (ej. NYSE) obligan cableado de LARGO IGUAL para todos: nadie compra 'el rack más cercano'
- ▶ Es una decisión regulatoria resolviendo con INGENIERÍA un problema de equidad

El arbitraje de latencia como una opción gratis (Budish-Cramton-Shim, 2015)


- ▶ **La idea: cotizar a precio fijo durante una ventana Δt es, matemáticamente, EMITIR una opción**
 - Quien te gana de velocidad la 'ejercita': te compra barato o te vende caro apenas conviene
 - Recordando la clase 2: un straddle = comprar un call + un put, mismo strike (ATM) y vencimiento — gana si el precio se mueve, no importa hacia dónde; cotizar fijo mientras el precio puede moverse en cualquier sentido es EMITIR ese straddle
- ▶ **El valor de esa opción regalada (straddle ATM a vencimiento Δt , vía Black-Scholes de la clase 2)**

$$V(\Delta t) \approx S_0 \sigma \sqrt{\frac{2\Delta t}{\pi}} \quad \Rightarrow \quad V \propto \sqrt{\Delta t}, \text{ no linealmente}$$


- Duplicar la ventana de latencia NO duplica el costo: lo multiplica por $\sqrt{2}$, rendimientos decrecientes

El arbitraje de latencia como una opción gratis

El valor de la opción que regala cada cotización, en función de Δt



La escalera $\sqrt{\Delta t}$: pendiente ≈ 0.5
no lineal, Budish-Cramton-Shim (2015)



Izquierda: el valor del straddle ATM exacto (Black-Scholes) y la aproximación de Bachelier coinciden casi a la perfección para Δt chico. Derecha: el ajuste log-log confirma la pendiente ≈ 0.5 — la escalera $\sqrt{\Delta t}$ de Budish-Cramton-Shim (2015), verificada numéricamente.

- ▶ **OFI: contar eventos en los primeros niveles del libro (nuevas órdenes, cancelaciones, ejecuciones)**

$$\text{OFI}_t = \sum_n e_n \quad \Delta P_t \approx \beta \frac{\text{OFI}_t}{AD_t}$$

- β juega EXACTAMENTE el papel de λ de Kyle (§2), pero medido evento a evento, no trade a trade

- ▶ **OBI: una FOTO del libro en un instante, no su flujo — mucho más simple de calcular**


$$\text{OBI}_t = \frac{q_t^B - q_t^A}{q_t^B + q_t^A} \in [-1, 1]$$

- ▶ Cont, Cucuringu & Zhang (2023) integran este OFI en 10 niveles y 7 tickers — mismo espíritu, más escala (bibliografía)


OFI vs OBI, con datos reales: el flujo gana a la foto

OFI vs OBI, con libro real (AAPL, 2026-08-06, 90 min, bloques de 30s)

OFI: el FLUJO evento a evento predice bien



OBI: la FOTO del libro predice mucho peor



Libro MBP-10 real (AAPL, 2026-08-06, primeros 90 min, bloques de 30s — el mismo tramo del λ de Kyle real-vs-simulado, §2). Izquierda: OFI evento a evento, $R^2=0.54$. Derecha: OBI, la foto del desbalance de tamaños en la punta, $R^2=0.09$ — sabe HACIA DÓNDE está inclinado el libro pero no CUÁNTO se está moviendo; el flujo (OFI) trae la información que la foto (OBI) no puede.

- ▶ **Un Poisson asume eventos independientes; en un libro real, un evento CAUSA más eventos**

- Una ejecución grande dispara cancelaciones defensivas y reposicionamiento de otros MMs, en milisegundos

- ▶ **La intensidad condicional: la tasa reacciona al pasado**

$$\lambda(t) = \mu + \sum_{t_i < t} \alpha e^{-\beta(t - t_i)}$$

- Cada evento agrega un salto de tamaño α , que decae con vida media $\ln 2 / \beta$ (el resorte, otra vez)
- ▶ Vale para eventos del libro (§5) y también para trades grandes reales (§3) — el mismo tipo de clustering

- ▶ **Cada TIPO de evento k (compras, ventas, cancelaciones... o activos distintos) tiene su propia intensidad**

$$\lambda_k(t) = \mu_k + \sum_j \sum_{t_i^j < t} \alpha_{kj} e^{-\beta_{kj}(t - t_i^j)}$$

- $\alpha_{\{kj\}}$: cuánto excita un evento de tipo j a la intensidad de tipo k — la matriz completa ES la red de quién dispara a quién
-
- ▶ **Un paso más allá, mencionado y no desarrollado: el Hawkes 'cuadrático' (Bouchaud-Maitrier)**
 - La intensidad depende del CUADRADO del desequilibrio de flujo pasado, no de su valor — hace falta para separar volatilidad de desequilibrio

Autoexcitación: por qué el flujo de órdenes no es Poisson


Poisson homogéneo, misma tasa media (106 eventos)



Hawkes exponencial, $n=\alpha/\beta=0.75$ (73 eventos): el clustering se ve a simple vista



Intensidad condicional: cada evento dispara un salto que decae



Un Hawkes exponencial ($n=0.75$) contra un Poisson de igual tasa media: el clustering se ve a simple vista en el panel del medio, ausente en el de arriba. Abajo, la intensidad condicional $\lambda(t)$ salta con cada evento y decae exponencialmente hasta el próximo.

- ▶ **Física (latencia) → Economía (opción gratis) → Señal (OFI) → Dinámica (Hawkes) → Sistemas (C++) → Patologías**
 - Cada eslabón depende del anterior: sin física no hay economía de la velocidad, sin economía no hay carrera,
 - sin carrera no hace falta C++, y cuando todo esto interactúa mal (Flash Crash) es porque cada pieza local funcionó bien

- ▶ OFI y Hawkes

Por qué hace falta C++ (mención, no desarrollo)

- ▶ **Todo lo de §5 asumió que el CÓMPUTO es instantáneo. No lo es**
 - Python es interpretado (paga un peaje en cada operación); C++ es compilado, corre a metal directo
 - Medido en esta máquina: sumar 50M de cuadrados es $\sim 47\text{-}67\times$ más rápido en C++ -O2 que en Python puro
 - El GIL de Python limita el cómputo paralelo real; C++ no lo tiene
- ▶ **Por qué esto NO contradice que todo el curso use Python**
 - Python no compite en el hot path (la ejecución de una orden), compite en TODO lo demás
- ▶ La arquitectura real de una firma con HFT: research en Python arriba, motor en C++ abajo

El Flash Crash: 6 de mayo de 2010, minuto a minuto


- ▶ El arco que abrimos en la clase 1 se cierra hoy, con el vocabulario matemático completo
- ▶ **14:32, un fondo vende 75.000 E-minis con un algoritmo POV (§3) sin límite de precio**
 - El algo acelera cuando el volumen sube... y el volumen sube porque él vende: feedback
- ▶ **14:41, los market makers algorítmicos (§4) hacen lo que su modelo dice: se retiran**
 - Inventario explotado + σ disparada $\rightarrow$ el precio de reserva se dispara $\rightarrow$ quotes MUY afuera
 - El libro queda VACÍO: la liquidez es un espejismo que se evapora cuando más se la necesita
- ▶ **14:45, el stop-logic del CME pausa 5 segundos... y eso ALCANZA. 15:08: todo recuperado**
- ▶ La fragilidad fue EMERGENTE: nadie violó ninguna regla, cada algoritmo hizo lo correcto localmente

El Flash Crash: la anatomía del colapso de liquidez

Flash Crash — simulación de colapso del mercado
(basado en Flash Crash del 6 de Mayo de 2010, S&P 500)



Colapso de la profundidad — los market makers retiran sus órdenes
(LOB vacuum: el libro queda casi vacío en el pico del crash)



Explosión del spread — sin profundidad, los ejecutores pagan precios irracionales




La cronología del 6 de mayo de 2010: el precio, el vaciamiento del libro y la recuperación. 36 minutos que produjeron una década de regulación, y el informe SEC-CFTC que inauguró el análisis forense con datos de LOB completos.

- ▶ **MiFID II (2018): el marco regulatorio europeo para mercados electrónicos y trading algorítmico**
 - Timestamps sincronizados a 100 microsegundos entre TODOS los participantes: reconstruir 'quién llegó primero' de verdad
 - Registro y testing obligatorio de cada algoritmo antes de ponerlo en producción (no autocertificación)
 - Ratios máximos de orden/trade: penaliza a quien cancela órdenes muchísimo más de lo que ejecuta (spoofing-adyacente)
- ▶ **El principio detrás del marco**
- ▶ No prohíbe la velocidad: exige TRAZABILIDAD y responsabilidad cuando algo sale mal a esa velocidad

- ▶ **Knight Capital, 1 de agosto de 2012: USD 440M perdidos en 45 minutos**
 - Un deploy dejó código viejo activo en UN servidor de ocho; una flag reciclada lo despertó
 - La lección: en trading algorítmico el riesgo OPERACIONAL domina, un bug ejecuta a la velocidad del stack
 - Consecuencia regulatoria: kill switches obligatorios para todos los broker-dealers
- ▶ **Spoofing y layering: manipulación a velocidad de máquina**
 - Poner órdenes grandes SIN intención de ejecutar, para simular presión, y cancelarlas
 - Ilegal (Dodd-Frank); la detección es hoy un problema de ML sobre el LOB (herramientas de clase 6)
- ▶ **El marco regulatorio detrás de estas protecciones: MiFID II (Europa, 2018)**
- ▶ Timestamps sincronizados a 100 μ s, registro obligatorio de algoritmos, ratios orden/trade máximos

Knight Capital: el riesgo operacional a velocidad de máquina

Knight Capital Group — 1 de Agosto 2012



Root cause: deploy de software defectuoso

1. Deploy parcial	2. Sin kill switch	3. Pre-trade risk débil	4. SEC violations
7 de 8 servidores actualizados. El 8vo corrió código viejo (de 2003) que interpretó flags nuevos como orden de comprar agresivamente.	No había mecanismo automático para detener al sistema cuando las pérdidas excedieron umbrales. Detención fue manual: 45 min después.	El sistema validaba orders individualmente, no AGREGADAMENTE. 4M shares/minuto pasaron los checks individuales.	Knight no notificó SEC en los primeros minutos. La SEC se enteró por terceros (BATS). Multa posterior: \$12M.

45 minutos de un bug de deployment: USD 440 millones y la empresa entera. En trading algorítmico, el riesgo operacional no es una nota al pie: es el que mata más rápido, y la razón de los kill switches obligatorios.

- ▶ **El resorte OU cierra su recorrido en el curso: 6 vidas, clase 2 → clase 3 (×2) → clase 7 → hoy (×2)**
- ▶ **El hilo de Black-Scholes (clase 2): la opción gratis de \$5 usa la MISMA matemática, otro contexto**
- ▶ **OFI y Hawkes (\$5): hoy desarrollados en serio — verosimilitud, branching ratio, la red multivariada**
- ▶ El checklist de higiene (clase 6): multiple testing, look-ahead, costos — exigido de nuevo hoy (\$3, Ejercicio 4)

CIE Cierre del curso RRE

un mismo lenguaje, escalas cada vez más chicas

El arco completo: de la macro al microsegundo

- 1 — El mapa: mercados, actores, tasas, FX, curvas (la foto macro)
 - 2 — Pricing I: opciones sin modelo, Black-Scholes (valuar)
 - 3 — Pricing II: volatilidad, tasas, crédito (el zoológico que usa la industria)
 - 4 — Econometría financiera: factores, series de tiempo (estimar lo que el pricing asume)

 - 5 — Teoría de portafolio: Markowitz, CAPM de equilibrio (de un activo a la cartera)
 - 6 — ML en finanzas (AFML): por qué falla el ML de manual, y cómo se hace bien
 - 7 — Arbitraje estadístico: cointegración, OU, Kalman (días-semanas)
 - 8 — Microestructura y HFT: el mismo libro de órdenes, hasta el microsegundo — HOY
- ▶ Un mismo lenguaje (control estocástico, inferencia bayesiana, el resorte OU) en escalas cada vez más chicas

▶ La misma matemática, contextos distintos

- El resorte OU, 6 vidas: clase 2 (nace) → clase 3 ×2 (Vasicek, el anticipo) → clase 7 (spread cointegrado) → clase 8 ×2 (κ de Almgren-Chriss, inventario de Avellaneda-Stoikov)
- Black-Scholes: nace en clase 2, reaparece en la opción gratis del arbitraje de latencia (clase 8 §5)
- El precio como estimador bayesiano recursivo: Kalman (clase 7) y Glosten-Milgrom (clase 8) son la MISMA matemática

▶ Decisiones de diseño del curso (a propósito, no casualidad)

- CAPM, dos veces: clase 4 como regresión empírica ($r_i = \alpha + \beta \cdot r_m + \epsilon$), clase 5 como equilibrio de mercado
- Los dos Avellaneda: Lee (clase 7, stat arb industrial) y Stoikov (clase 8, market making) — mismo apellido, problemas opuestos

▶ Disciplina metodológica, exigida una y otra vez

- ▶ El checklist (clase 6: multiple testing, look-ahead, costos) se exige de nuevo en clase 7 y clase 8

METODOLOGÍA

De la hipótesis al capital real

El protocolo, no el resultado: cómo se construye una estrategia que sobrevive a ponerse a prueba

Paso 1: el mecanismo económico antes que el número

- ▶ **Una señal sin interpretación económica es un patrón, no una estrategia**
 - La pregunta obligatoria: ¿quién está del otro lado de esta operación, y por qué acepta perder exactamente lo que yo gano?
- ▶ **Tres fuentes legítimas de retorno (no se excluyen entre sí)**
 - Compensación por riesgo: el otro lado cobra una prima por asumir un riesgo que no quiere (CAPM, clase 5; carry; iliquidez)
 - Fricción estructural: el otro lado opera por un motivo no-económico (cobertura regulatoria, rebalanceo de índice, orden con deadline) — Avellaneda-Stoikov (§4) explota exactamente esto
 - Ineficiencia de procesamiento: el mercado tarda en incorporar información (Kyle, §2) — más frágil, más competida, decae más rápido
- ▶ Si no podés nombrar cuál de las tres es la tuya, todavía no tenés una estrategia — tenés una correlación

Paso 2: la hipótesis tiene que poder morir

- ▶ **El principio de falsación: una hipótesis científica es la que especifica, de antemano, qué resultado la refutaría**
 - 'Este par cointegra y revierte' es falseable: un test de Engle-Granger con $p > 0.05$ lo mata (clase 7, Ej.1)
 - 'El mercado tiene ineficiencias que un modelo suficientemente flexible puede encontrar' NO es falseable — ningún resultado la refuta, por diseño
 - Este es el error estructural que la clase 6 (§1-§2) diagnosticó en el ML aplicado sin cuidado: optimizar hasta encontrar ALGO, sin haber arriesgado nada de antemano
- ▶ **Corolario operativo: escribir la hipótesis y el criterio de rechazo ANTES de mirar el resultado del test, no después**

Paso 3: congelar las reglas antes de backtestear

- ▶ **El pre-registro: la misma disciplina que un ensayo clínico o un experimento controlado — las reglas se fijan antes de ver el resultado**
- ▶ **Lo que se congela ANTES de correr un solo backtest, por escrito**
 - Universo exacto (qué activos, con qué filtro de inclusión — sin supervivencia, clase 6 §2)
 - Señal exacta: la fórmula, no una descripción ('reversión a la media' no alcanza; $z = (p_t - \mu_{60d})/\sigma_{60d}$ sí)
 - Reglas de entrada, salida y stop; tamaño de posición; frecuencia de rebalanceo
 - Benchmark y horizonte de evaluación (cuántos trades out-of-sample hacen falta para decidir)

Paso 4: el backtest no vale nada sin fricciones realistas

► Cada fricción ignorada es un sesgo optimista, en la misma dirección siempre

- Bid-ask spread: operar al mid es ficción — hay que cruzar el spread en cada pata (§2, Stoll)
- Slippage y fills realistas: nunca asumir fill garantizado al precio de la señal, ni en la misma barra en que se generó (eso es look-ahead encubierto)
- Comisiones y fees del bróker/exchange — chicos por operación, no chicos acumulados a alta frecuencia
- Impacto de mercado: la propia orden mueve el precio si el tamaño no es trivial frente al volumen (Almgren-Chriss, §3; sqrt-law, Ej.4)
- Liquidez y capacidad: ¿el volumen diario soporta el tamaño sin que la estrategia sea el 20-30% del volumen? (Avellaneda-Lee, clase 7 §5, el límite de capacidad)
- Costos de posición corta: borrow fee, riesgo de recall (el prestamista pide el título de vuelta en el peor momento), dividendos a pagar mientras se está corto
- Latencia: el delta de tiempo entre señal y ejecución, que en microestructura (§5) ya es una fuente de pérdida por sí sola

Paso 5: tratar de matar la propia estrategia


- ▶ **El sesgo natural es defenderla — el protocolo exige lo opuesto: atacarla con todo lo disponible**
 - Walk-forward: re-estimar y testear en ventanas que avanzan en el tiempo, nunca un único split in/out
 - Bootstrap de los trades: si remuestreando el orden de los retornos el resultado colapsa, dependía de la secuencia, no de la señal
 - Shuffle de la señal (control aleatorio): correr el mismo backtest con la señal mezclada al azar — si el Sharpe no cae a ≈ 0 , el backtest tiene una fuga (look-ahead, supervivencia)
 - Subperíodos y regímenes: ¿sobrevive 2008, 2020, subas de tasas Y bajas de tasas? Una estrategia que solo funciona en un régimen no está probada, está sobreajustada al período
 - Sensibilidad de parámetros: perturbar cada parámetro $\pm 20\%$ — un óptimo que es una aguja en un pajar no es un óptimo robusto, es ruido
 - Deflated Sharpe Ratio (clase 6 §7): corrige el Sharpe por CUÁNTAS variantes se probaron de verdad — exigir $DSR > 0.95$, no Sharpe bruto alto
 - ¿Depende de 2-3 trades extremos? Sacarlos y volver a medir — si el resultado se cae, la muestra era insuficiente para la afirmación

Paso 6, 7 y 8: empezar despacio, siempre

- ▶ **Paper trading: ejecución simulada con fills realistas (§2, §3), en tiempo real, SIN capital en riesgo — expone bugs de implementación que ningún backtest histórico muestra**
 - Capital real mínimo: recién acá aparecen fricciones operativas genuinas (errores de conectividad, rechazos de orden, el costo psicológico de perder plata real) que ninguna simulación reproduce
 - Escalado gradual, condicionado: aumentar tamaño SOLO mientras el tracking error entre el P&L vivo y el P&L del backtest se mantenga dentro de lo esperado por el ruido muestral
 - Monitoreo continuo del decaimiento de la señal: el mercado se adapta (más competencia encuentra la misma ineficiencia) — una estrategia que funcionó no tiene garantía de seguir funcionando
- ▶ Criterio de apagado, escrito de antemano: igual que el criterio de rechazo del Paso 2, definir ANTES qué divergencia sostenida entre lo vivo y lo esperado implica apagar la estrategia, no 'esperar que vuelva'

De la hipótesis al capital real: un proceso falsacionista

rechazo: diverge sistemáticamente del backtest en vivo



Ocho pasos con dos circuitos de rechazo explícitos: la estrategia puede morir en el Paso 5 (no sobrevive el intento de refutarla con fricciones realistas) o en el Paso 7 (el live diverge sistemáticamente del backtest). En ambos casos, 'rechazo' es el resultado correcto del protocolo, no un fracaso del proceso — es exactamente lo que el método científico está diseñado para producir cuando corresponde.